

Phân loại và dự đoán tình trạng sức khỏe thai nhi thông qua dữ liệu Cardiotocogram (CTG)

Machine Learning

Nhóm 16

Đinh Bảo Triết – 23000164

Đỗ Minh Hoàng – 23000121

Vũ Nhân Tông – 23000160

Trường Đại học Khoa học Tự nhiên – ĐHQGHN
Khoa Toán – Cơ – Tin học

Hà Nội – 2026

Nội dung trình bày

- 1 Giới thiệu
- 2 Dữ liệu
- 3 Phương pháp
- 4 Kết quả
- 5 Kết luận

- Cardiotocography (CTG) được dùng để theo dõi nhịp tim thai và cơn co tử cung.
- Việc đọc biểu đồ CTG bằng mắt thường phụ thuộc khá nhiều vào kinh nghiệm lâm sàng.
- Học máy có thể hỗ trợ quá trình sàng lọc và đánh giá ban đầu một cách nhất quán và nhanh hơn.
- Trong bối cảnh y khoa, việc bỏ sót các trường hợp bệnh lý là rất nguy hiểm.
- Vì vậy, việc xây dựng mô hình hỗ trợ phát hiện sớm các dấu hiệu bất thường từ dữ liệu CTG là cần thiết.

Mục tiêu, phạm vi và tiêu chí đánh giá

Mục tiêu và phạm vi

- Xây dựng quy trình xử lý dữ liệu CTG.
- So sánh PCA, LDA với dữ liệu gốc sau chuẩn hóa.
- Đánh giá Gaussian Naive Bayes, Softmax Regression và SVM.
- Khảo sát trên các tỉ lệ train:test 8:2, 7:3 và 6:4.
- Tinh chỉnh trọng số lớp để ưu tiên phát hiện **Pathological**.

Tiêu chí đánh giá

- Chỉ số sử dụng: Accuracy, Precision, Recall và Macro F1.
- Trọng tâm: **Recall lớp Pathological**.
- Lớp bệnh lý ít mẫu nhất nhưng chi phí bỏ sót cao hơn.
- Accuracy chỉ dùng để tham khảo thêm trong bối cảnh mất cân bằng lớp.

Tổng quan và làm sạch dữ liệu

Bộ dữ liệu


- Nguồn dữ liệu: **Fetal Health Classification** (Kaggle).
- Kích thước ban đầu: **2.126 bản ghi**; sau loại **13 dòng trùng lặp** còn **2.113**.
- Missing values: **0**.
- Số thuộc tính: **21 đặc trưng số + 1 nhãn**.
- Biến mục tiêu: `fetal_health` với 3 nhãn.

Nhóm đặc trưng chính

- Tín hiệu cơ bản: baseline value, fetal movement, uterine contractions.
- Gia tốc và giảm tốc: accelerations, light/severe/prolongued decelerations.
- Biến thiên: short-term variability và long-term variability.
- Histogram: width, min, max, mean, median, variance, tendency.

Các nhóm đặc trưng có thang đo khác nhau nên cần chuẩn hóa trước khi huấn luyện.

Biểu đồ phân phối lớp




- **Normal:** 77,9%
- **Suspect:** 13,8%
- **Pathological:** 8,3%

Vì lớp bệnh lý rất ít, mô hình vẫn có thể đạt Accuracy khá cao nhưng bỏ sót nhiều ca nguy cơ cao.

Do đó nhóm ưu tiên:


- Recall lớp Pathological
- Macro F1
- Accuracy để tham khảo thêm

Boxplot



- Một số đặc trưng có nhiều giá trị ngoại lệ.
- Các điểm này không bị loại bỏ tự động vì có thể phản ánh tín hiệu bất thường.

Phân tích tương quan




- Nhóm đặc trưng histogram có tương quan với nhau rất cao ($r > 0,9$).
- Các biến accelerations và prolonged_decelerations tương quan đáng kể với nhãn mục tiêu.
- Tương quan cao giải thích lý do nhóm khảo sát thêm PCA và LDA.
- Tuy vậy, tương quan cao không đồng nghĩa giảm chiều chắc chắn làm mô hình tốt hơn.

Chuẩn hóa dữ liệu


- Các đặc trưng của bộ CTG có độ lớn rất khác nhau.
- Nếu không chuẩn hóa, các biến lớn sẽ chi phối khoảng cách và quá trình tối ưu.
- Nhóm sử dụng chuẩn hóa Z-score bằng StandardScaler.
- Tham số μ_j, σ_j ước lượng **chỉ trên X_{train}** , sau đó transform cả X_{train} và X_{test} – tránh data leakage.

$$z_i^{(j)} = \frac{x_i^{(j)} - \mu_j}{\sigma_j}$$

PCA: chọn số chiều và trực quan hóa 2D



Cần **14 thành phần** để giữ $\geq 95\%$ phương sai.



PC1 và PC2 chỉ giữ khoảng **45,58%** phương sai toàn bộ dữ liệu.

- Trên mặt phẳng PC1–PC2, hai lớp Normal và Suspect còn chồng lẫn đáng kể.
- Vì PCA không dùng nhãn, phép chiếu 2D phù hợp để trực quan hóa hơn là tách lớp trực tiếp.

Giảm chiều: so sánh PCA và LDA


PCA

- Không giám sát, giữ phương sai lớn nhất.
- Phù hợp để nén dữ liệu và trực quan hóa.

LDA


- Có giám sát, tối đa hóa khả năng tách lớp.
- Với 3 lớp, LDA tạo tối đa 2 trục mới.

Với bộ CTG, PCA giúp quan sát cấu trúc tổng quát, còn LDA tạo không gian biểu diễn tách lớp rõ hơn.



LDA tách Normal và Pathological rõ hơn, Suspect nằm giữa.

Khảo sát K-Means (phân tích bổ sung)



K-Means ($k = 4$) trên không gian PCA 2D

- K-Means chỉ dùng để khảo sát cấu trúc dữ liệu, **không phải mô hình dự đoán**.
- $k = 4$ được chọn từ biểu đồ silhouette.
- Purity = 0,79 nhưng ARI = 0,10 và NMI = 0,19 – cấu trúc cụm không tương ứng tốt với nhãn y khoa.
- Kết quả này phản ánh tính phức tạp và mất cân bằng của dữ liệu.

Mô hình khảo sát

- Gaussian Naive Bayes
- Softmax Regression
- SVM với kernel RBF

Không gian dữ liệu

- Dữ liệu gốc sau chuẩn hóa
- Dữ liệu PCA (14 chiều)
- Dữ liệu LDA (2 chiều)

Thiết lập đánh giá

- Tỷ lệ train:test: 8:2, 7:3, 6:4
- $\Rightarrow$ 27 mô hình thực nghiệm
- Chỉ số: Accuracy, Macro F1, Recall theo lớp, confusion matrix, ROC
- Trọng tâm: **Recall lớp Pathological**

Hạng mục	Giá trị
Dữ liệu	LDA
Train:test	6:4
Train	87,85%
Test	86,76%
Chênh lệch	1,08%

Mô hình tốt nhất của Naive Bayes trong 27 thực nghiệm.

- LDA cho kết quả tốt nhất: **86,76%** trên tập kiểm tra.
- Naive Bayes hưởng lợi rõ từ không gian chiều có giám sát.
- So với dữ liệu gốc, độ chính xác tăng mạnh sau giảm chiều.
- Kết luận: với GNB, **LDA phù hợp hơn PCA** và dữ liệu gốc.

Softmax Regression

Hạng mục	Giá trị
Dữ liệu	Gốc
Train:test	6:4
Train	90,06%
Test	89,72%
Chênh lệch	0,34%

Softmax là mô hình ổn định nhất trong ba họ mô hình khảo sát.

- Mô hình tốt nhất dùng **dữ liệu gốc** với tỉ lệ 6:4.
- Accuracy đạt **89,72%**, chênh lệch train–test chỉ **0,34%**.
- PCA và LDA không cải thiện thêm cho Softmax.
- Kết luận: Softmax ổn định, nhưng vẫn thấp hơn SVM trên dữ liệu gốc.

SVM trước khi tăng trọng số lớp

Lớp	Precision	Recall	F1-score
Normal	0,93	0,98	0,95
Suspect	0,76	0,59	0,67
Pathological	0,93	0,77	0,84
Accuracy	0,91		

Cấu hình nền: dữ liệu gốc, train:test = 7:3, kernel='rbf', probability=True, chưa dùng class_weight.

- Accuracy tổng thể khoảng **0,91** – nhìn qua có vẻ tốt.
- Nhưng Recall lớp **Pathological** chỉ đạt **0,77** – bỏ sót $\approx 23\%$ ca bệnh.
- Đây là hạn chế nghiêm trọng trong bối cảnh y khoa.

Tác động của `class_weight`

Mô hình	Accuracy	Recall Pathological	F1 Pathological
SVM gốc (7:3)	0,91	0,77	0,84
SVM cân bằng lớp	0,9069	0,94	0,91

Mô hình cân bằng lớp dùng `kernel='rbf'`, `probability=True`, `train:test = 7:3` và `class_weight={1.0:1, 2.0:3, 3.0:7}`.



- Recall lớp bệnh lý tăng mạnh từ **0,77** lên **0,94** (−17% bỏ sót).
- Accuracy chỉ giảm nhẹ ($0,91 \rightarrow 0,9069$).
- Đây là sự đánh đổi hợp lý và có chủ đích trong dữ liệu y khoa mất cân bằng.

Kết quả mô hình cuối cùng

Lớp	Precision	Recall	F1-score
Normal	0,98	0,91	0,95
Suspect	0,63	0,85	0,72
Pathological	0,88	0,94	0,91
Macro avg	0,83	0,90	0,86
Weighted avg	0,92	0,91	0,91
Accuracy	90,69%		

```
kernel='rbf', probability=True | train:test = 7:3  
class_weight={1.0:1, 2.0:3, 3.0:7}
```

Ma trận nhầm lẫn và đường cong ROC



ROC: AUC class 1=0,98 | class 2=0,91 | class 3=0,99

Ma trận nhầm lẫn – mô hình cuối

Sai số còn lại chủ yếu là nhầm lẫn Normal $\leftrightarrow$ Suspect – chấp nhận được hơn so với bỏ sót lớp bệnh lý.

- Nhóm đã xây dựng quy trình học máy hoàn chỉnh: làm sạch → chia tập → chuẩn hóa → giảm chiều → huấn luyện → đánh giá.
- SVM trên dữ liệu gốc là mô hình nền tốt nhất trong 27 mô hình thực nghiệm.
- `class_weight={1.0:1, 2.0:3, 3.0:7}` giúp Recall lớp Pathological đạt **0,94**.
- Với dữ liệu y khoa mất cân bằng: cần ưu tiên chỉ số theo lớp, không chỉ nhìn Accuracy.
- Giảm chiều (PCA/LDA) không cải thiện đồng đều – hiệu quả phụ thuộc vào từng mô hình cụ thể.

Chuyển đổi sang bài toán hồi quy

Cách thực hiện

- Lấy mô hình SVM cuối cùng tại tỉ lệ train:test = 7:3.
- Dùng `predict_proba` của lớp **Pathological** làm biến mục tiêu liên tục.
- Huấn luyện Linear Regression và KNN Regressor ($k = 5$).
- So sánh trên dữ liệu gốc và dữ liệu PCA còn 1/3 số chiều.

Kết quả hồi quy

Mô hình	R^2	MSE
Linear (gốc)	0,6446	0,0194
KNN (gốc)	0,9173	0,0045
Linear (PCA)	0,5300	0,0256
KNN (PCA)	0,9050	0,0052

KNN Regressor xấp xỉ xác suất bệnh lý tốt hơn Linear Regression; PCA làm hiệu năng giảm nhẹ.

- Áp dụng **stratified k-fold cross-validation** để tăng độ tin cậy thống kê.
- Thử thêm các mô hình tổ hợp như Random Forest hoặc XGBoost.



TS. Cao Văn Chung, **Bài giảng Học máy**, Trường Đại học Khoa học Tự nhiên – ĐHQGHN.



Fetal Health Classification, bộ dữ liệu Kaggle.

<https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>

Cảm ơn thầy và các bạn đã lắng nghe!

Rất mong nhận được câu hỏi và góp ý.