

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - CƠ - TIN HỌC



BÁO CÁO CUỐI KỲ

**PHÂN LOẠI VÀ DỰ ĐOÁN TÌNH TRẠNG
SỨC KHỎE THAI NHI
THÔNG QUA DỮ LIỆU
CARDIOTOCOGRAM (CTG)
MACHINE LEARNING**

Ngành: Toán Tin
Mã học phần: MAT3533
Nhóm thực hiện: Nhóm 16

Giảng viên hướng dẫn: TS. Cao Văn Chung

Sinh viên thực hiện: Đinh Bảo Triết - 23000164
Đỗ Minh Hoàng - 23000121
Vũ Nhân Tông - 23000160

Hà Nội - 2026

Mục lục

Tóm tắt	3
Mở đầu	4
1 Cơ sở lý thuyết	6
1.1 Chuẩn hóa dữ liệu (Standardization)	6
1.2 Phân tích thành phần chính (PCA)	7
1.3 Phân tích phân biệt tuyến tính (LDA)	7
1.4 Phân cụm K-Means	8
1.5 Phân loại Gaussian Naive Bayes	8
1.6 Hồi quy Softmax (Softmax Regression)	9
1.7 Support Vector Machine với nhân RBF (SVM - Kernel RBF)	9
2 Phương pháp thực nghiệm	11
2.1 Mô tả tập dữ liệu	11
2.1.1 Nguồn gốc và cấu trúc	11
2.1.2 Kiểm tra kiểu dữ liệu và tính đầy đủ	14
2.1.3 Phân phối nhãn và mất cân bằng	14
2.1.4 Thống kê mô tả và phát hiện ngoại lệ	15
2.1.5 Phân tích tương quan	17
2.1.6 Vai trò của dữ liệu trong bài toán	17
2.2 Tiền xử lý dữ liệu	18
2.2.1 Đọc và thống kê dữ liệu	18
2.2.2 Làm sạch	18
2.2.3 Chuẩn hóa	18
2.2.4 Dữ liệu sau khi chuẩn hóa	18
2.3 Giảm chiều và trực quan hóa	19
2.3.1 PCA – chọn số chiều	19
2.3.2 Trực quan hóa PCA 2D	20
2.3.3 Trực quan hóa LDA	21
2.3.4 So sánh PCA và LDA cho bài toán CTG	22

2.4	Phân cụm K-Means khảo sát	23
2.5	Quy trình huấn luyện và đánh giá	24
2.5.1	Phân chia dữ liệu	24
2.5.2	Các mô hình so sánh	24
2.5.3	Chỉ số đánh giá	24
2.5.4	Cài đặt tham số	25
2.5.5	Quy trình thực nghiệm	25
3	Kết quả thực nghiệm	26
3.1	Kết quả phân loại trên các cấu hình thực nghiệm	26
3.2	Ma trận nhầm lẫn của các mô hình tốt nhất	27
3.3	Đánh giá overfitting	28
3.4	Lựa chọn và tinh chỉnh mô hình cuối cùng	28
3.5	Chuyển đổi sang bài toán hồi quy – mô phỏng xác suất của SVM	31
3.6	Thảo luận	32
	Kết luận	34
	Hạn chế	34
	Đề xuất hướng phát triển	35

Tóm tắt

Báo cáo này trình bày quá trình xây dựng hệ thống hỗ trợ đánh giá tình trạng sức khỏe thai nhi dựa trên dữ liệu Cardiotocography (CTG).

Mô hình tập trung vào bài toán phân loại tình trạng thai nhi thành ba nhóm: Bình thường (Normal), Nghi ngờ (Suspect) và Bệnh lý (Pathological). Việc nhận diện sớm các dấu hiệu bất thường từ tín hiệu nhịp tim thai và cơn co tử cung có ý nghĩa quan trọng trong theo dõi thai kỳ và hỗ trợ ra quyết định lâm sàng.

Quy trình thực nghiệm gồm các bước: làm sạch dữ liệu, loại bỏ bản ghi trùng lặp, phân chia tập huấn luyện và kiểm tra, chuẩn hóa đặc trưng bằng `StandardScaler`, giảm chiều bằng PCA và LDA, sau đó huấn luyện các mô hình Gaussian Naive Bayes, Softmax Regression và Support Vector Machine. Kết quả thực nghiệm trên các tỉ lệ chia 8:2, 7:3 và 6:4 cho thấy dữ liệu có mất cân bằng lớp rõ rệt; vì vậy, việc đánh giá mô hình được đặt trọng tâm vào Recall của lớp Pathological, bên cạnh Macro F1 và Accuracy.

Kết quả cho thấy SVM trên dữ liệu gốc đạt hiệu năng cao và ổn định nhất. Sau khi hiệu chỉnh trọng số lớp theo cấu hình $\{1.0:1, 2.0:3, 3.0:7\}$, mô hình đạt Accuracy 90,69%, Recall 0,94 và F1-score 0,91 đối với lớp Pathological. Các kết quả này cho thấy mô hình có khả năng nhận diện tốt các trường hợp nguy cơ cao, đồng thời vẫn duy trì được mức chính xác tổng thể phù hợp cho bài toán hỗ trợ chẩn đoán.

Mở đầu

Lý do chọn đề tài

Tử vong thai nhi và tử vong sơ sinh vẫn là vấn đề có ý nghĩa lớn trong thực hành sản khoa. Cardiotocography (CTG) hiện là công cụ lâm sàng quan trọng để theo dõi nhịp tim thai và cơn co tử cung, qua đó hỗ trợ phát hiện sớm các dấu hiệu suy thai. Tuy nhiên, việc diễn giải biểu đồ CTG bằng quan sát trực tiếp phụ thuộc đáng kể vào kinh nghiệm chuyên môn, đồng thời tiềm ẩn sự khác biệt giữa những người đọc. Trong bối cảnh đó, việc ứng dụng các phương pháp học máy vào bài toán phân loại kết quả CTG có ý nghĩa thiết thực cả về mặt học thuật lẫn khả năng hỗ trợ quyết định lâm sàng.

Mục tiêu

Dự án được thực hiện với các mục tiêu sau:

- Xây dựng quy trình xử lý dữ liệu phù hợp cho bộ dữ liệu CTG, bao gồm làm sạch, chuẩn hóa và tổ chức đặc trưng;
- Khảo sát và so sánh hiệu quả của các phương pháp giảm chiều PCA và LDA trong bối cảnh dữ liệu y sinh;
- Huấn luyện các mô hình Gaussian Naive Bayes, Softmax Regression và Support Vector Machine để phân loại tình trạng thai nhi thành ba nhóm Normal, Suspect và Pathological;
- Đánh giá và hiệu chỉnh mô hình theo hướng ưu tiên khả năng nhận diện lớp bệnh lý trong điều kiện dữ liệu mất cân bằng.

Đối tượng và phạm vi

- **Đối tượng:** Các mô hình Học máy có giám sát và không giám sát truyền thống.
- **Phạm vi dữ liệu:** Mô hình được giới hạn trên tập dữ liệu *Fetal Health Classification* được công bố trên Kaggle. Bộ dữ liệu bao gồm 2.126 bản ghi bệnh án với 22 thuộc tính số học được trích xuất từ thiết bị CTG.
- **Phạm vi thực nghiệm:** Các mô hình được đánh giá trên nhiều tỷ lệ phân chia tập Huấn luyện/Kiểm thử (Train:Test) gồm 8:2, 7:3 và 6:4 theo cơ chế stratified splitting để giữ ổn định phân phối nhãn giữa các tập. Đồng thời, mô hình cũng mở rộng đánh giá việc chuyển đổi bài toán phân loại sang bài toán hồi quy nhằm xấp xỉ xác suất đầu ra do SVM ước lượng.

Tổng quan các hướng tiếp cận liên quan

Bộ dữ liệu CTG được sử dụng trong báo cáo là bộ *Fetal Health Classification* được chia sẻ trên Kaggle [2]. Đây là một bài toán phân loại trên dữ liệu bảng y sinh, trong đó mỗi mẫu là một véc-tơ đặc trưng số mô tả trạng thái theo dõi thai nhi. Trên dạng dữ liệu này, các phương pháp học máy cổ điển vẫn là nhóm mô hình nền quan trọng nhờ quy trình huấn luyện rõ ràng, chi phí tính toán vừa phải và khả năng diễn giải kết quả tương đối tốt [1].

Trong số các kỹ thuật hỗ trợ phân tích dữ liệu, PCA và LDA thường được dùng để giảm chiều hoặc trực quan hóa dữ liệu nhiều biến; trong khi Gaussian Naive Bayes, hồi quy logistic đa lớp và SVM là các mô hình tiêu biểu cho phân loại trên dữ liệu số có kích thước vừa phải [1]. Với các bộ dữ liệu y khoa có mất cân bằng lớp, việc chỉ sử dụng Accuracy làm tiêu chí đánh giá là chưa đủ; vì vậy báo cáo này ưu tiên Recall của lớp Pathological, đồng thời sử dụng thêm Macro F1 để phản ánh chất lượng dự đoán trên toàn bộ ba lớp.

Chương 1

Cơ sở lý thuyết

Chương này tóm tắt ngắn gọn các phương pháp được sử dụng trong báo cáo, với trọng tâm là: giả định của mô hình, công thức cốt lõi, ý nghĩa thực nghiệm và mối liên hệ với bộ dữ liệu CTG. Mục tiêu của phần này không phải là trình bày đầy đủ mọi chứng minh, mà là làm rõ vì sao từng phương pháp phù hợp với bài toán và cách chúng được triển khai trong thực nghiệm. Việc lựa chọn các mô hình trong báo cáo bám theo những phương pháp nền tảng thường gặp trong học máy và nhận dạng mẫu [1].

1.1 Chuẩn hóa dữ liệu (Standardization)

Trong bộ dữ liệu CTG, các đặc trưng có thang đo rất khác nhau. Ví dụ, nhịp tim cơ bản có thể vào khoảng hàng trăm bpm, trong khi một số đặc trưng như `accelerations` hoặc `severe_decelerations` chỉ có giá trị rất nhỏ. Nếu không chuẩn hóa, các đặc trưng có độ lớn lớn sẽ chi phối khoảng cách Euclidean và làm méo quá trình tối ưu của các mô hình như K-Means, Softmax hay SVM [1].

Phương pháp được sử dụng trong báo cáo là chuẩn hóa Z-score. Với đặc trưng thứ j , ta tính trung bình mẫu μ_j và độ lệch chuẩn mẫu σ_j trên tập huấn luyện, sau đó biến đổi:

$$z_i^{(j)} = \frac{x_i^{(j)} - \mu_j}{\sigma_j}, \quad i = 1, \dots, N, \quad j = 1, \dots, D.$$

Sau biến đổi này, mỗi đặc trưng có trung bình xấp xỉ 0 và phương sai xấp xỉ 1. Trong toàn bộ thực nghiệm, các tham số μ_j, σ_j chỉ được ước lượng trên tập huấn luyện, rồi áp dụng lại cho tập kiểm tra để tránh rò rỉ thông tin.

1.2 Phân tích thành phần chính (PCA)

PCA là phương pháp giảm chiều không giám sát, tìm một không gian con tuyến tính sao cho lượng phương sai được giữ lại là lớn nhất [1]. Sau khi dữ liệu được chuẩn hóa, ma trận hiệp phương sai có thể viết dưới dạng:

$$\mathbf{S} = \frac{1}{N} \mathbf{X}^\top \mathbf{X},$$

trong đó $\mathbf{X} \in \mathbb{R}^{N \times D}$ là ma trận dữ liệu đã được đưa về trung bình 0. PCA chọn các vector riêng ứng với các trị riêng lớn nhất của $\mathbf{S}$ để tạo thành ma trận chiếu $\mathbf{U}_K$, rồi chiếu dữ liệu xuống không gian K chiều:

$$\mathbf{Z} = \mathbf{X} \mathbf{U}_K.$$

Trong báo cáo này, PCA được dùng cho hai mục đích. Thứ nhất, PCA 2 chiều hỗ trợ trực quan hóa cấu trúc dữ liệu. Thứ hai, PCA với ngưỡng phương sai tích lũy 95% cho phép rút gọn số chiều nhưng vẫn giữ lại phần lớn thông tin, từ đó kiểm tra xem việc giảm tương quan đặc trưng có cải thiện hiệu năng phân loại hay không.

1.3 Phân tích phân biệt tuyến tính (LDA)

Khác với PCA, LDA là phương pháp giảm chiều có giám sát: nó sử dụng nhãn lớp để tìm một phép chiếu sao cho các mẫu cùng lớp gần nhau hơn, còn tâm của các lớp cách xa nhau hơn [1]. Hai đại lượng trung tâm là ma trận phân tán nội lớp và giữa các lớp:

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{i \in \mathcal{D}_c} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top,$$

$$\mathbf{S}_B = \sum_{c=1}^C N_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top.$$

LDA tìm ma trận chiếu $\mathbf{W}$ sao cho tỉ lệ phân tán giữa lớp trên phân tán nội lớp là lớn nhất; về mặt tính toán, điều này dẫn tới bài toán trị riêng tổng quát của $\mathbf{S}_W^{-1} \mathbf{S}_B$.

Một tính chất quan trọng là $\text{rank}(\mathbf{S}_B) \leq C - 1$, nên với bài toán CTG có $C = 3$ lớp thì LDA chỉ có thể trích xuất tối đa 2 đặc trưng mới. Vì vậy, LDA đặc biệt phù hợp để trực quan hóa dữ liệu 3 lớp và kiểm tra xem thông tin nhãn có giúp tách lớp rõ hơn không.

1.4 Phân cụm K-Means

K-Means là thuật toán phân cụm không giám sát dùng để chia dữ liệu thành K cụm bằng cách cực tiểu tổng bình phương khoảng cách từ mỗi điểm tới tâm cụm của nó:

$$\mathcal{L}(\mathbf{R}, \mathbf{M}) = \sum_{i=1}^N \sum_{k=1}^K r_{ik} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|_2^2,$$

trong đó $r_{ik} \in \{0, 1\}$ là biến gán cụm và $\boldsymbol{\mu}_k$ là tâm cụm thứ k . Thuật toán lặp giữa hai bước: gán mỗi điểm vào tâm gần nhất và cập nhật lại tâm bằng trung bình của các điểm trong cụm.

Trong mô hình này, K-Means không được sử dụng như mô hình dự đoán cuối cùng mà chỉ đóng vai trò khảo sát cấu trúc dữ liệu sau giảm chiều. Do giả định các cụm có dạng gần hình cầu và độ nhạy đối với dữ liệu mất cân bằng, kết quả K-Means cần được diễn giải thận trọng trong bối cảnh dữ liệu y khoa.

1.5 Phân loại Gaussian Naive Bayes

Gaussian Naive Bayes (GNB) là bộ phân loại sinh dựa trên định lý Bayes với giả định độc lập có điều kiện giữa các đặc trưng khi biết nhãn lớp [1]. Với lớp c , ta có:

$$P(y = c \mid \mathbf{x}) \propto P(y = c) \prod_{j=1}^D P(x_j \mid y = c).$$

Với dữ liệu liên tục, mỗi thành phần được giả định tuân theo phân phối Gaussian:

$$P(x_j \mid y = c) = \frac{1}{\sqrt{2\pi\sigma_{cj}^2}} \exp\left(-\frac{(x_j - \mu_{cj})^2}{2\sigma_{cj}^2}\right).$$

Để tránh underflow, quá trình suy luận thường được viết ở miền log:

$$c^* = \arg \max_c \left[\log P(y = c) - \frac{1}{2} \sum_{j=1}^D \left(\log(2\pi\sigma_{cj}^2) + \frac{(x_j - \mu_{cj})^2}{\sigma_{cj}^2} \right) \right].$$

Ưu điểm của GNB là đơn giản, nhanh và dễ diễn giải. Tuy nhiên, mô hình này nhạy với tương quan mạnh giữa các đặc trưng; vì vậy trong thực nghiệm của báo cáo, GNB thường hưởng lợi rõ hơn khi dữ liệu được giảm chiều bằng PCA hoặc LDA.

1.6 Hồi quy Softmax (Softmax Regression)

Softmax Regression là mở rộng của logistic regression cho bài toán đa lớp [1]. Với mỗi lớp $c = 1, \dots, C$, mô hình gán một logit:

$$z_c = \mathbf{w}_c^\top \mathbf{x} + b_c,$$

rồi chuyển các logit thành xác suất bằng hàm softmax:

$$a_c = P(y = c \mid \mathbf{x}) = \frac{\exp(z_c)}{\sum_{j=1}^C \exp(z_j)}.$$

Hàm mất mát cơ bản là cross-entropy:

$$\mathcal{L}(\mathbf{W}) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{ic} \log a_{ic}.$$

Nếu dùng hiệu chỉnh L2, dạng đầy đủ của hàm mục tiêu là:

$$\mathcal{L}_{\text{reg}}(\mathbf{W}) = \mathcal{L}(\mathbf{W}) + \frac{\lambda}{2} \|\mathbf{W}\|_F^2,$$

và gradient tương ứng là

$$\nabla_{\mathbf{W}} \mathcal{L}_{\text{reg}} = \frac{1}{N} \mathbf{X}^\top (\mathbf{A} - \mathbf{Y}) + \lambda \mathbf{W}.$$

Trong cài đặt thực nghiệm, mô hình này được triển khai bằng `LogisticRegression(solver='lbfgs', max_iter=1000)`, tức là một bộ giải tối ưu số cho bài toán multinomial logistic regression.

1.7 Support Vector Machine với nhân RBF (SVM - Kernel RBF)

SVM tìm siêu phẳng có lề lớn nhất để phân loại dữ liệu [1]. Với bài toán không tách tuyến tính, báo cáo sử dụng nhân RBF:

$$k(\mathbf{x}, \mathbf{z}) = \exp\left(-\gamma \|\mathbf{x} - \mathbf{z}\|_2^2\right), \quad \gamma > 0.$$

Bài toán soft-margin ở dạng primal là:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^N \xi_i,$$

với ràng buộc $y_i(\mathbf{w}^\top \Phi(\mathbf{x}_i) + b) \geq 1 - \xi_i$, $\xi_i \geq 0$. Trong dạng đối ngẫu, cần phân biệt rõ:

$$K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$$

là ma trận kernel, còn

$$Q_{ij} = y_i y_j K_{ij}$$

là ma trận xuất hiện trong hạng tử toàn phương của bài toán dual. Khi đó bài toán đối ngẫu có dạng:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j Q_{ij},$$

với $0 \leq \alpha_i \leq C$ và $\sum_i \alpha_i y_i = 0$. Hàm quyết định cho một điểm mới là:

$$f(\mathbf{x}) = \sum_{i \in SV} \alpha_i y_i k(\mathbf{x}_i, \mathbf{x}) + b.$$

Hai siêu tham số quan trọng nhất là C và γ . Tham số C điều khiển mức phạt cho các điểm vi phạm lề, còn γ điều khiển độ cục bộ của kernel RBF. Trong bài toán CTG, SVM đặc biệt phù hợp vì có thể học ranh giới phi tuyến ngay trên không gian đặc trưng gốc sau chuẩn hóa.

Vì dữ liệu CTG có 3 lớp, phần thực nghiệm không dùng SVM nhị phân thuần túy mà dùng triển khai đa lớp của `scikit-learn` `SVC`. Thư viện này xử lý đa lớp theo chiến lược one-vs-one. Để ưu tiên phát hiện lớp bệnh lý, báo cáo còn sử dụng trọng số lớp ở mô hình cuối cùng. Cụ thể, mô hình SVM tinh chỉnh được triển khai bằng `SVC(kernel='rbf', probability=True, class_weight={1.0:1, 2.0:3, 3.0:7})`. Trong phần kết quả, đường cong ROC được dựng từ `decision_function` của mô hình này, còn bài toán hồi quy mô phỏng sử dụng đầu ra `predict_proba` cho lớp Pathological.

Chương 2

Phương pháp thực nghiệm

2.1 Mô tả tập dữ liệu

2.1.1 Nguồn gốc và cấu trúc

Tập dữ liệu **Fetal Health Classification** được trích xuất từ các bản ghi Cardiotocogram (CTG), trong đó mỗi mẫu tương ứng với một lần theo dõi sức khỏe thai nhi. Dữ liệu có cấu trúc hoàn toàn số học, phù hợp cho các mô hình phân loại truyền thống và các kỹ thuật giảm chiều. Bộ dữ liệu được nhóm sử dụng từ nguồn chia sẻ trên Kaggle [2]. Bảng 2.1 tóm tắt các thông số nền tảng của bộ dữ liệu được sử dụng trong báo cáo.

Bảng 2.1: Tổng quan các thông số chính của bộ dữ liệu CTG

Thông số	Giá trị
Nguồn dữ liệu	Kaggle – <i>Fetal Health Classification</i>
Số bản ghi ban đầu	2.126
Số bản ghi sau làm sạch	2.113
Số thuộc tính đầu vào	21
Biến mục tiêu	<code>fetal_health</code>
Số lớp đầu ra	3 lớp: Normal, Suspect, Pathological
Kiểu dữ liệu	Toàn bộ thuộc tính ở dạng số (float/integer)
Giá trị khuyết thiếu	Không có
Số bản ghi trùng lặp bị loại bỏ	13
Mục tiêu bài toán	Phân loại đa lớp và mô phỏng xác suất bệnh lý

Ngoài các thông số tổng quan, 22 thuộc tính của dữ liệu được diễn giải trực tiếp trong mục này để thuận tiện cho việc đối chiếu với quá trình xử lý và xây dựng mô hình. Trong phần mô tả dưới đây, báo cáo dùng tên cột theo dạng quen thuộc trong mã nguồn Python với dấu gạch dưới.

- Các chỉ số về nhịp tim và cử động thai (tính trên mỗi giây):**
 - `baseline_value`: Nhịp tim cơ bản của thai nhi (FHR – Fetal Heart Rate).
 - `accelerations`: Số lần tăng nhịp tim thai, tức số gia tốc mỗi giây.
 - `fetal_movement`: Số cử động của thai nhi mỗi giây.
 - `uterine_contractions`: Số lần co thắt tử cung mỗi giây.
 - `light_decelerations`: Số lần giảm nhịp tim thai nhẹ (LD).
 - `severe_decelerations`: Số lần giảm nhịp tim thai nghiêm trọng (SD).
 - `prolongued_decelerations`: Số lần giảm nhịp tim thai kéo dài (PD). Tên cột `prolongued_decelerations` được giữ

nguyên theo bộ dữ liệu gốc trên Kaggle (chính tả đúng là *prolonged*), nên đây không phải lỗi đánh máy của nhóm.

- **Các chỉ số về sự dao động nhịp tim (Variability):**

- `abnormal_short_term_variability`: Tỷ lệ phần trăm thời gian nhịp tim thai có mức dao động ngắn hạn (STV) bất thường.
- `mean_value_of_short_term_variability`: Giá trị trung bình của dao động nhịp tim ngắn hạn.
- `percentage_of_time_with_abnormal_long_term_variability`: Tỷ lệ phần trăm thời gian nhịp tim thai có mức dao động dài hạn (LTV) bất thường.
- `mean_value_of_long_term_variability`: Giá trị trung bình của dao động nhịp tim dài hạn.

- **Các chỉ số trích xuất từ biểu đồ tần suất (Histogram) của nhịp tim:**

- `histogram_width`: Độ rộng của biểu đồ, tức khoảng chênh lệch giữa nhịp tim cao nhất và thấp nhất.
- `histogram_min`: Mức nhịp tim thấp nhất ghi nhận được trên biểu đồ.
- `histogram_max`: Mức nhịp tim cao nhất ghi nhận được trên biểu đồ.
- `histogram_number_of_peaks`: Số lượng đỉnh trên biểu đồ, thể hiện các nhịp tim lặp lại nhiều lần.
- `histogram_number_of_zeroes`: Số lượng điểm có giá trị bằng 0 trên biểu đồ.
- `histogram_mode`: Giá trị nhịp tim xuất hiện nhiều nhất (mode) trên biểu đồ.
- `histogram_mean`: Giá trị nhịp tim trung bình (mean) trên biểu đồ.
- `histogram_median`: Giá trị nhịp tim trung vị (median) trên biểu đồ.
- `histogram_variance`: Phương sai, phản ánh độ phân tán nhịp tim của biểu đồ.

- **histogram_tendency**: Xu hướng của biểu đồ; thường quy ước -1 là lệch trái/giảm, 0 là đối xứng hoặc bình thường, và 1 là lệch phải/tăng.

- **Biến mục tiêu: fetal_health** biểu diễn tình trạng sức khỏe thai nhi, trong đó lớp 1 là Bình thường, lớp 2 là Nghi ngờ – cần theo dõi thêm, và lớp 3 là Bệnh lý – bất thường, có cảnh báo nguy hiểm.

2.1.2 Kiểm tra kiểu dữ liệu và tính đầy đủ

Việc kiểm tra từng cột cho thấy bộ dữ liệu có chất lượng đầu vào tốt: toàn bộ biến đều ở dạng số, không có giá trị khuyết thiếu và số lượng quan sát hợp lệ đồng nhất giữa các cột. Nhờ đó, quy trình xử lý dữ liệu có thể tập trung trực tiếp vào các bước làm sạch, chuẩn hóa và xây dựng mô hình, không cần bổ sung thao tác mã hóa hay nội suy dữ liệu thiếu. Bảng 2.2 trình bày chi tiết thông tin của 22 cột trong bộ dữ liệu gốc.


Bảng 2.2: Thông tin kiểu dữ liệu và độ đầy đủ của các cột trong bộ dữ liệu gốc

#	Column	Non-Null Count	Dtype
0	baseline value	2126 non-null	float64
1	accelerations	2126 non-null	float64
2	fetal_movement	2126 non-null	float64
3	uterine_contractions	2126 non-null	float64
4	light_decelerations	2126 non-null	float64
5	severe_decelerations	2126 non-null	float64
6	prolongued_decelerations	2126 non-null	float64
7	abnormal_short_term_variability	2126 non-null	float64
8	mean_value_of_short_term_variability	2126 non-null	float64
9	percentage_of_time_with_abnormal_long_term_variability	2126 non-null	float64
10	mean_value_of_long_term_variability	2126 non-null	float64
11	histogram_width	2126 non-null	float64
12	histogram_min	2126 non-null	float64
13	histogram_max	2126 non-null	float64
14	histogram_number_of_peaks	2126 non-null	float64
15	histogram_number_of_zeroes	2126 non-null	float64
16	histogram_mode	2126 non-null	float64
17	histogram_mean	2126 non-null	float64
18	histogram_median	2126 non-null	float64
19	histogram_variance	2126 non-null	float64
20	histogram_tendency	2126 non-null	float64
21	fetal_health	2126 non-null	float64

2.1.3 Phân phối nhãn và mất cân bằng

Biến mục tiêu **fetal_health** gồm ba lớp: Normal (77,9%), Suspect (13,8%) và Pathological (8,3%). Phân phối này cho thấy sự mất cân bằng lớp khá rõ, trong đó lớp Normal chiếm tỉ trọng lớn nhất. Vì vậy, Accuracy tổng thể chưa phản ánh đầy đủ chất lượng mô hình; các chỉ số theo lớp, đặc biệt là Recall của lớp Pathological, có ý nghĩa quan trọng

hơn trong bối cảnh ứng dụng y khoa. Hình 2.1 trình bày phân phối tần suất của ba lớp.



Hình 2.1: Phân phối số lượng mẫu của 3 trạng thái sức khỏe thai nhi


2.1.4 Thống kê mô tả và phát hiện ngoại lệ

Bảng 2.3 trình bày thống kê mô tả của dữ liệu sau khi loại bỏ các bản ghi trùng lặp. Kết quả cho thấy thang đo giữa các biến khác biệt đáng kể: một số đặc trưng như `accelerations` hoặc `severe_decelerations` có giá trị rất nhỏ, trong khi nhóm biến histogram biến thiên trên khoảng rộng hơn. Bên cạnh đó, chênh lệch tương đối lớn giữa tứ phân vị trên và giá trị cực đại ở một số đặc trưng gợi ý sự hiện diện của các quan sát cực trị. Trong bối cảnh dữ liệu y khoa, các quan sát này có thể phản ánh những trạng thái bất thường có giá trị phân loại, nên được giữ lại trong quá trình phân tích.

Bảng 2.3: Thống kê mô tả dữ liệu sau làm sạch

Feature	count	mean	std	min	25%	50%	75%	max
baseline value	2113	133.30	9.84	106.0	126.0	133.0	140.0	160.0
accelerations	2113	0.0032	0.0039	0.0	0.0	0.002	0.006	0.019
fetal_movement	2113	0.0095	0.0468	0.0	0.0	0.0	0.003	0.481
uterine_contractions	2113	0.0044	0.0029	0.0	0.002	0.005	0.007	0.015
light_decelerations	2113	0.0019	0.0030	0.0	0.0	0.0	0.003	0.015
severe_decelerations	2113	0.0000	0.0001	0.0	0.0	0.0	0.0	0.001
prolongued_decelerations	2113	0.0002	0.0006	0.0	0.0	0.0	0.0	0.005
abnormal_short_term								
variability	2113	46.99	17.18	12.0	32.0	49.0	61.0	87.0
mean_value_of								
short_term								
variability	2113	1.34	0.88	0.2	0.7	1.2	1.7	7.0
percentage_of_time								
with_abnormal								
long_term								
variability	2113	9.80	18.34	0.0	0.0	0.0	11.0	91.0
mean_value_of								
long_term								
variability	2113	8.17	5.63	0.0	4.6	7.4	10.8	50.7
histogram_width	2113	70.54	39.01	3.0	37.0	68.0	100.0	180.0
histogram_min	2113	93.56	29.56	50.0	67.0	93.0	120.0	159.0
histogram_max	2113	164.10	17.95	122.0	152.0	162.0	174.0	238.0
histogram_number								
of_peaks	2113	4.08	2.95	0.0	2.0	4.0	6.0	18.0
histogram_number								
of_zeroes	2113	0.33	0.71	0.0	0.0	0.0	0.0	10.0
histogram_mode	2113	137.45	16.40	60.0	129.0	139.0	148.0	187.0
histogram_mean	2113	134.60	15.61	73.0	125.0	136.0	145.0	182.0
histogram_median	2113	138.09	14.48	77.0	129.0	139.0	148.0	186.0
histogram_variance	2113	18.91	29.04	0.0	2.0	7.0	24.0	269.0
histogram_tendency	2113	0.32	0.61	-1.0	0.0	0.0	1.0	1.0
fetal_health	2113	1.30	0.61	1.0	1.0	1.0	1.0	3.0


Hình 2.2 trực quan hóa các ngoại lệ này dưới dạng biểu đồ hộp và củng cố nhận xét rằng dữ liệu có độ phân tán không đồng đều giữa các đặc trưng.



Hình 2.2: Biểu đồ hộp

2.1.5 Phân tích tương quan

Ma trận tương quan Pearson (Hình 2.3) cho thấy nhóm đặc trưng histogram có tương quan với nhau rất cao ($r > 0.9$). Các biến **accelerations** và **prolongued_decelerations** có tương quan đáng kể với biến mục tiêu; ba biến dao động còn lại cũng nổi bật là tỷ lệ STV bất thường, tỷ lệ LTV bất thường và giá trị trung bình của LTV.



Hình 2.3: Ma trận tương quan giữa các đặc trưng

2.1.6 Vai trò của dữ liệu trong bài toán

Bộ dữ liệu CTG là cơ sở cho toàn bộ quá trình phân tích trong báo cáo, từ tiền xử lý đến đánh giá mô hình. Với cấu trúc nhất quán và ý nghĩa lâm sàng tương đối rõ ràng, bộ dữ liệu này cho phép nghiên cứu tập trung vào ba hướng chính:

- xây dựng mô hình phân loại tình trạng sức khỏe thai nhi thành ba nhóm Normal, Suspect và Pathological;
- phân tích mối liên hệ giữa các đặc trưng sinh lý và biến mục tiêu nhằm hỗ trợ diễn giải kết quả;
- so sánh hiệu quả của các phương pháp học máy trên cùng một cơ sở dữ liệu đã được chuẩn hóa.

2.2 Tiền xử lý dữ liệu

2.2.1 Đọc và thống kê dữ liệu

Dữ liệu được đọc từ tệp CSV bằng **Pandas**. Các kiểm tra ban đầu xác nhận số lượng biến, số bản ghi, tính đầy đủ của dữ liệu và sự nhất quán về kiểu dữ liệu. Do mọi thuộc tính đều ở dạng số, dữ liệu có thể được đưa trực tiếp vào các bước chuẩn hóa, giảm chiều và huấn luyện mô hình mà không cần xử lý mã hóa bổ sung.

2.2.2 Làm sạch

Quá trình làm sạch dữ liệu gồm hai bước chính: loại bỏ 13 bản ghi trùng lặp và kiểm tra tính đầy đủ của từng cột. Không phát hiện giá trị khuyết thiếu. Các quan sát cực trị không bị loại bỏ, vì trong ngữ cảnh y khoa chúng có thể phản ánh những trạng thái sinh lý bất thường có giá trị đối với bài toán phân loại.

2.2.3 Chuẩn hóa

Lưu ý về thứ tự thực hiện: Trong toàn bộ thực nghiệm, dữ liệu được phân chia thành tập huấn luyện và tập kiểm tra *trước* khi thực hiện bất kỳ bước chuẩn hóa nào. **StandardScaler** chỉ được fit trên **X_train**, sau đó mới transform cả **X_train** lẫn **X_test**. Cách làm này đảm bảo không có thông tin của tập kiểm tra rò rỉ vào quá trình học tham số chuẩn hóa (data leakage).

Dùng **StandardScaler** (Z-score) để đưa mỗi đặc trưng về trung bình 0 và phương sai 1 trên tập huấn luyện. Bước này là bắt buộc đối với bộ dữ liệu CTG vì các biến có đơn vị đo và độ lớn khác nhau rõ rệt; nếu không chuẩn hóa, các đặc trưng có biên độ lớn sẽ chi phối khoảng cách và hàm mục tiêu của mô hình.

2.2.4 Dữ liệu sau khi chuẩn hóa

Sau chuẩn hóa, các đặc trưng đầu vào được đưa về cùng một thang đo, qua đó hạn chế ảnh hưởng chi phối của những biến có độ lớn lớn hơn trong quá trình tối ưu. Bảng 2.4 cho thấy trung bình của các biến sau biến đổi xấp xỉ 0 và độ lệch chuẩn xấp xỉ 1. Biến mục tiêu **fetal_health** không được chuẩn hóa vì đây là nhãn phân lớp, không phải đặc trưng đầu vào.

Bảng 2.4: Thống kê dữ liệu sau chuẩn hóa Z-score

Feature	mean	std	min	max
baseline value	0.0000	1.0002	-2.7763	2.7143
accelerations	0.0000	1.0002	-0.8238	4.0853
fetal_movement	0.0000	1.0002	-0.2034	10.0760
uterine_contractions	0.0000	1.0002	-1.4922	3.6099
light_decelerations	0.0000	1.0002	-0.6412	4.4180
severe_decelerations	0.0000	1.0002	-0.0577	17.3452
prolongued_decelerations	0.0000	1.0002	-0.2696	8.1836
abnormal_short_term				
variability	0.0000	1.0002	-2.0376	2.3295
mean_value_of				
short_term				
variability	0.0000	1.0002	-1.2837	6.4072
percentage_of_time				
with_abnormal				
long_term				
variability	0.0000	1.0002	-0.5343	4.4295
mean_value_of				
long_term				
variability	0.0000	1.0002	-1.4502	7.5527
histogram_width	0.0000	1.0002	-1.7317	2.8069
histogram_min	0.0000	1.0002	-1.4740	2.2140
histogram_max	0.0000	1.0002	-2.3466	4.1191
histogram_number				
of_peaks	0.0000	1.0002	-1.3816	4.7181
histogram_number				
of_zeroes	0.0000	1.0002	-0.4602	13.6721
histogram_mode	0.0000	1.0002	-4.7234	3.0214
histogram_mean	0.0000	1.0002	-3.9470	3.0372
histogram_median	0.0000	1.0002	-4.2202	3.3098
histogram_variance	0.0000	1.0002	-0.6513	8.6144
histogram_tendency	0.0000	1.0002	-2.1582	1.1155


2.3 Giảm chiều và trực quan hóa

2.3.1 PCA – chọn số chiều

PCA trên dữ liệu chuẩn hóa cho thấy hai thành phần chính đầu tiên giải thích lần lượt 28,86% và 16,72% phương sai, tức cộng lại chỉ giữ được 45,58% mức biến thiên của toàn bộ dữ liệu. Điều này cho thấy biểu diễn trên mặt phẳng PC1–PC2 chủ yếu phù hợp cho mục đích trực quan hóa, chứ chưa phản ánh đầy đủ phần lớn thông tin ban đầu. Bảng 2.5 trình bày tỷ lệ phương sai và phương sai tích lũy của từng thành phần chính; kết quả cho thấy cần 14 thành phần để giữ ít nhất 95% phương sai, khi đó phương sai tích lũy đạt 96,32% (Hình 2.4).

Bảng 2.5: Tỷ lệ phương sai và phương sai tích lũy của các thành phần chính trong PCA


Thành phần chính	Tỷ lệ phương sai (%)	Phương sai tích lũy (%)
PC1	28.86	28.86
PC2	16.72	45.58
PC3	8.66	54.24
PC4	7.09	61.34
PC5	5.80	67.14
PC6	4.87	72.00
PC7	4.67	76.68
PC8	4.42	81.09
PC9	3.63	84.73
PC10	3.05	87.78
PC11	2.74	90.52
PC12	2.38	92.90
PC13	1.85	94.75
PC14	1.56	96.32
PC15	1.26	97.58
PC16	0.86	98.44
PC17	0.64	99.07
PC18	0.56	99.64
PC19	0.24	99.87
PC20	0.13	100.00
PC21	0.00	100.00



Hình 2.4: Tỷ lệ phương sai tích lũy theo số PC

2.3.2 Trực quan hóa PCA 2D


Chiếu lên PC1, PC2 (Hình 2.5) cho thấy các lớp đan xen, đặc biệt giữa Normal và Suspect – hệ quả của PCA không dùng nhãn.



Hình 2.5: Phân tán 3 lớp trong không gian PCA 2D

2.3.3 Trực quan hóa LDA

LDA (có giám sát) tạo 2 thành phần với tỷ lệ phương sai 80.31% và 19.69%. Hình 2.6 cho thấy Normal và Pathological tách biệt rõ rệt, Suspect nằm giữa, phản ánh đúng tính chất y khoa.



Hình 2.6: Không gian đặc trưng 2 chiều do LDA tạo ra

2.3.4 So sánh PCA và LDA cho bài toán CTG


Bảng 2.6: So sánh PCA và LDA trong bài toán phân loại sức khỏe thai nhi

Tiêu chí	PCA	LDA
Loại học	Không giám sát	Có giám sát
Dùng nhãn lớp	Không	Có
Mục tiêu chính	Giữ phương sai lớn nhất	Tách lớp tốt nhất
Số chiều tối đa	Không phụ thuộc số lớp	$\leq C - 1$
Vai trò trong CTG	Nén dữ liệu, trực quan hóa	Tăng khả năng phân biệt lớp

Đối với bộ dữ liệu CTG, PCA phù hợp với mục tiêu nén dữ liệu và trực quan hóa vì không sử dụng thông tin nhãn, trong khi LDA khai thác trực tiếp thông tin lớp để tăng khả năng phân tách. Vì vậy, PCA thích hợp khi cần bảo toàn phần lớn phương sai của dữ liệu, còn LDA phù hợp hơn khi mục tiêu chính là hỗ trợ phân loại. Kết quả thực nghiệm ở chương sau cho thấy nhận định này thể hiện rõ với Naive Bayes, trong khi SVM và Softmax không cải thiện đáng kể sau giảm chiều.

2.4 Phân cụm K-Means khảo sát

K-Means được áp dụng với $k = 4$ trên dữ liệu sau khi chiếu xuống không gian PCA hai chiều như một cấu hình khảo sát để quan sát mức độ phân tách tự nhiên của dữ liệu. Trong phạm vi báo cáo, lựa chọn này giúp cân bằng giữa khả năng diễn giải trực quan và mức độ chi tiết của các cụm. Hình 2.7 minh họa kết quả phân cụm.



Hình 2.7: K-Means ($k=4$) trên không gian PCA 2D

Bảng 2.7: Ma trận nhầm lẫn giữa phân cụm K-Means và nhãn thực

y_true \ cluster	0	1	2	3
1.0 (Normal)	539	631	82	394
2.0 (Suspect)	17	31	12	232
3.0 (Pathological)	9	0	109	57

Các độ đo đánh giá thu được là Purity = 0,7918, ARI = 0,0964 và NMI = 0,1877. Giá trị Purity tương đối cao chủ yếu phản ánh ảnh hưởng của lớp đa số, trong khi ARI và NMI ở mức thấp cho thấy cấu trúc phân cụm của K-Means không tương ứng chặt chẽ với cấu trúc nhãn y khoa. Kết quả này xác nhận vai trò của K-Means trong báo cáo chỉ là khảo sát cấu trúc, không phải mô hình dự đoán.

2.5 Quy trình huấn luyện và đánh giá

2.5.1 Phân chia dữ liệu

Dữ liệu được chia theo cơ chế stratified splitting với các tỉ lệ 8:2, 7:3 và 6:4. Như đã nêu ở mục 2.5.1, bước phân chia này được thực hiện *trước* khi fit `StandardScaler`, nhằm đảm bảo tính độc lập giữa tập huấn luyện và tập kiểm tra trong suốt quy trình.

2.5.2 Các mô hình so sánh

Các mô hình được khảo sát gồm Gaussian Naive Bayes (GNB), Softmax Regression và SVM với nhân RBF, $C = 1$, $\gamma = \text{scale}$.

2.5.3 Chỉ số đánh giá

Trong nghiên cứu này, Recall của lớp 3 (Pathological) được ưu tiên vì đây là lớp có ý nghĩa lâm sàng cao nhất. Bên cạnh đó, báo cáo sử dụng thêm Macro F1 để phản ánh mức độ cân bằng giữa các lớp và Accuracy để theo dõi hiệu năng tổng thể.

Các kết quả định lượng trong Chương 3 được trình bày chủ yếu qua bảng tổng hợp độ chính xác trên tập huấn luyện, độ chính xác trên tập kiểm tra và độ chênh lệch giữa hai giá trị này (Train – Test). Với dữ liệu mất cân bằng, Accuracy không phải tiêu chí duy nhất; việc diễn giải kết quả luôn được đặt trong tương quan với Recall của lớp Pathological, Macro F1 và ma trận nhầm lẫn.

Khi diễn giải ma trận nhầm lẫn cho bài toán đa lớp, mỗi lớp được xét theo cơ chế one-vs-rest. Với một lớp đích bất kỳ (ví dụ lớp Pathological):

- **True Positive (TP):** số mẫu thật sự thuộc lớp đó và được dự đoán đúng là lớp đó;
- **True Negative (TN):** số mẫu không thuộc lớp đó và cũng không bị dự đoán vào lớp đó;
- **False Positive (FP):** số mẫu không thuộc lớp đó nhưng bị dự đoán nhầm thành lớp đó;
- **False Negative (FN):** số mẫu thật sự thuộc lớp đó nhưng bị dự đoán sang lớp khác.

Từ bốn đại lượng này, các chỉ số được hiểu như sau:

$$\text{Precision} = \frac{TP}{TP + FP},$$

$$\text{Recall} = \frac{TP}{TP + FN},$$

$$\text{Specificity} = \frac{TN}{TN + FP}.$$

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN},$$

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Trong đó, **support** trong các bảng báo cáo phân loại là số mẫu thật của từng lớp trong tập kiểm tra. Ở ngữ cảnh y khoa, FN của lớp Pathological tương ứng với các ca bệnh bị bỏ sót, nên đây là đại lượng cần được hạn chế tối đa.

2.5.4 Cài đặt tham số

Các mô hình được triển khai bằng thư viện `scikit-learn`. Cụ thể, Softmax được cài đặt bằng `LogisticRegression(solver='lbfgs', max_iter=1000)`; SVM nền được cài đặt bằng `SVC(kernel='rbf', probability=True)`; còn GNB được giữ ở dạng chuẩn không dùng trọng số lớp. Đối với mô hình SVM cuối cùng, trọng số lớp được đặt là `{1.0:1, 2.0:3, 3.0:7}` nhằm tăng mức ưu tiên cho lớp bệnh lý.

2.5.5 Quy trình thực nghiệm

Quy trình thực nghiệm được tiến hành theo các bước: làm sạch dữ liệu, phân chia tập train/test (stratified), chuẩn hóa đặc trưng (fit trên `X_train`), huấn luyện mô hình trên dữ liệu gốc và dữ liệu sau giảm chiều (PCA 14 chiều, LDA 2 chiều), sau đó đánh giá kết quả.

Chương 3

Kết quả thực nghiệm

3.1 Kết quả phân loại trên các cấu hình thực nghiệm

Bảng 3.1 tổng hợp độ chính xác trên tập huấn luyện, độ chính xác trên tập kiểm tra và độ chênh lệch (Train – Test) của ba mô hình trên ba dạng dữ liệu (gốc, PCA, LDA) với ba tỉ lệ chia 8:2, 7:3 và 6:4. Việc trình bày đầy đủ các cấu hình cho phép đối chiếu trực tiếp hiệu quả giữa mô hình, dạng dữ liệu và mức độ ổn định giữa tập huấn luyện với tập kiểm tra.

Bảng 3.1: Độ chính xác trên tập huấn luyện, tập kiểm tra và độ chênh lệch (Train – Test) của 27 cấu hình thực nghiệm


Tỉ lệ	Dữ liệu	Mô hình	Huấn luyện	Kiểm tra	Chênh lệch
8:2	Gốc	Naive Bayes	71.83%	70.92%	0.91%
8:2	PCA	Naive Bayes	84.85%	82.98%	1.87%
8:2	LDA	Naive Bayes	88.17%	84.16%	4.00%
8:2	Gốc	Softmax Regression	90.24%	88.89%	1.35%
8:2	PCA	Softmax Regression	89.94%	88.65%	1.29%
8:2	LDA	Softmax Regression	89.41%	87.47%	1.94%
8:2	Gốc	SVM	93.14%	90.31%	2.83%
8:2	PCA	SVM	92.60%	90.07%	2.53%
8:2	LDA	SVM	90.71%	89.36%	1.35%
7:3	Gốc	Naive Bayes	72.41%	68.45%	3.96%
7:3	PCA	Naive Bayes	85.26%	83.12%	2.14%
7:3	LDA	Naive Bayes	88.17%	85.65%	2.52%
7:3	Gốc	Softmax Regression	90.33%	89.43%	0.90%
7:3	PCA	Softmax Regression	90.06%	89.43%	0.63%
7:3	LDA	Softmax Regression	89.72%	87.85%	1.87%
7:3	Gốc	SVM	93.04%	91.01%	2.03%
7:3	PCA	SVM	92.56%	90.54%	2.03%
7:3	LDA	SVM	91.08%	87.85%	3.22%
6:4	Gốc	Naive Bayes	70.17%	67.85%	2.32%
6:4	PCA	Naive Bayes	85.24%	84.52%	0.73%
6:4	LDA	Naive Bayes	87.85%	86.76%	1.08%
6:4	Gốc	Softmax Regression	90.06%	89.72%	0.34%
6:4	PCA	Softmax Regression	90.06%	89.24%	0.81%
6:4	LDA	Softmax Regression	89.66%	88.42%	1.24%
6:4	Gốc	SVM	93.45%	90.90%	2.55%
6:4	PCA	SVM	92.82%	90.31%	2.51%
6:4	LDA	SVM	91.71%	88.53%	3.18%

Từ Bảng 3.1 có thể thấy SVM trên dữ liệu gốc với tỉ lệ 7:3 đạt độ chính xác trên tập kiểm tra cao nhất, ở mức 91.01%. Softmax Regression cho kết quả ổn định trong khoảng 88.65%–89.72%, trong khi Naive Bayes cải thiện đáng kể sau giảm chiều, đặc biệt với LDA, nơi độ chính xác trên tập kiểm tra đạt 86.76% ở tỉ lệ 6:4.

3.2 Ma trận nhầm lẫn của các mô hình tốt nhất

Hình 3.1 tổng hợp ma trận nhầm lẫn của bốn mô hình có hiệu suất cao:

- SVM (gốc, 7:3)
- SVM (gốc, 8:2)
- SVM (PCA, 7:3)
- Softmax (gốc, 6:4)



Hình 3.1: Ma trận nhầm lẫn của bốn mô hình tốt nhất

3.3 Đánh giá overfitting

Độ chênh lệch giữa độ chính xác trên tập huấn luyện và tập kiểm tra của 27 cấu hình được trình bày trong Bảng 3.1. Naive Bayes có độ chênh từ 0.73% đến 4.00%; Softmax Regression là mô hình ổn định nhất với độ chênh không vượt quá 1.94%; còn SVM có độ chênh từ 1.35% đến 3.22%. Giá trị lớn nhất xuất hiện ở cấu hình SVM trên dữ liệu LDA với tỉ lệ 7:3, cho thấy việc nén dữ liệu xuống hai chiều bằng LDA có thể làm suy giảm một phần khả năng khái quát của mô hình.

3.4 Lựa chọn và tinh chỉnh mô hình cuối cùng

SVM trên dữ liệu gốc với tỉ lệ 7:3 được chọn làm mô hình nền vì đây là cấu hình cho Accuracy cao và tương đối ổn định, đồng thời cho phép

đánh giá rõ hạn chế còn lại ở lớp bệnh lý trước khi tiến hành hiệu chỉnh trọng số. Kết quả chi tiết của mô hình chưa cân bằng được trình bày như sau:

Bảng 3.2: SVM gốc (7:3) – chưa cân bằng


	precision	recall	f1-score	support
Normal	0,93	0,98	0,95	494
Suspect	0,76	0,59	0,67	88
Pathological	0,93	0,77	0,84	52
Accuracy		0,91		634
macro avg	0,87	0,78	0,82	634
weighted avg	0,91	0,91	0,90	634

Recall của lớp Pathological ở mô hình nền chỉ đạt 0,77, tương đương với việc bỏ sót khoảng 23% số ca bệnh trong tập kiểm tra. Để khắc phục hạn chế này, mô hình tăng trọng số lớp theo cấu hình `class_weight={1.0:1, 2.0:3, 3.0:7}`. Kết quả sau hiệu chỉnh được trình bày dưới đây:


Bảng 3.3: SVM với `class_weight={1.0:1, 2.0:3, 3.0:7}` (7:3)

	precision	recall	f1-score	support
Normal	0,98	0,91	0,95	494
Suspect	0,63	0,85	0,72	88
Pathological	0,88	0,94	0,91	52
Accuracy		0,9069		634
macro avg	0,83	0,90	0,86	634
weighted avg	0,92	0,91	0,91	634

Sau hiệu chỉnh, Recall của lớp bệnh lý tăng lên 0,94, tương ứng với tỉ lệ bỏ sót khoảng 6%, trong khi Accuracy vẫn duy trì ở mức 90,69%. Kết quả này cho thấy mô hình chấp nhận giảm nhẹ độ chính xác trên lớp đa số để cải thiện đáng kể khả năng phát hiện các trường hợp nguy cơ cao. Hình 3.2 trình bày ma trận nhầm lẫn, còn Hình 3.3 thể hiện đường cong ROC của mô hình SVM cuối cùng.



Hình 3.2: Ma trận nhầm lẫn của mô hình SVM cuối cùng



Hình 3.3: Đường cong ROC cho ba lớp (SVM cuối cùng)

Bên cạnh lớp Pathological, mô hình còn đạt Recall 0,85 ở lớp Suspect. Giá trị trung bình macro đối với precision, recall và F1-score lần lượt là 0,83; 0,90; 0,86; còn giá trị trung bình có trọng số tương ứng là 0,92; 0,91; 0,91. Ở cấu hình SVM nền với tỉ lệ 7:3, độ chênh giữa độ chính xác trên tập huấn luyện và tập kiểm tra vào khoảng 2,03%, cho thấy mô hình có mức độ ổn định chấp nhận được trước và sau khi hiệu chỉnh trọng số. Xét trên phương diện ứng dụng, việc ưu tiên tăng độ nhạy của lớp Pathological là phù hợp, vì chi phí bỏ sót ca bệnh nghiêm trọng thường lớn hơn chi phí dự báo nhầm ở lớp đa số.

3.5 Chuyển đổi sang bài toán hồi quy – mô phỏng xác suất của SVM


Từ mô hình SVM đã hiệu chỉnh trọng số ở tỉ lệ 7:3, mô hình sử dụng xác suất dự đoán của lớp Pathological từ `predict_proba` làm biến mục tiêu liên tục, sau đó huấn luyện hai mô hình hồi quy là Linear Regression và KNN Regressor ($k = 5$) trên dữ liệu gốc và trên dữ liệu PCA giảm còn 1/3 số chiều. Cách tiếp cận này là **phân tích bổ sung** nhằm khảo sát mức độ mà các mô hình hồi quy có thể xấp xỉ đầu ra xác suất của SVM, không phải bước pipeline phân loại chính. Kết quả được trình bày trong Bảng 3.4.

Bảng 3.4: Kết quả hồi quy mô phỏng xác suất bệnh lý

Mô hình	R^2	MSE
Linear Regression (gốc)	0,6446	0,0194
KNN Regressor (gốc)	0,9173	0,0045
Linear Regression (PCA)	0,5300	0,0256
KNN Regressor (PCA)	0,9050	0,0052

Phù hợp với các chỉ số trong Bảng 3.4, KNN Regressor xấp xỉ xác suất đầu ra của SVM tốt hơn rõ rệt so với Linear Regression trên cả dữ liệu gốc lẫn dữ liệu PCA. Việc giảm số chiều bằng PCA xuống còn 1/3 số đặc trưng làm giảm nhẹ hiệu năng của cả hai mô hình hồi quy.

Đánh giá mô hình



Hình 3.4: So sánh xác suất SVM và xác suất hồi quy cho lớp Pathological

3.6 Thảo luận

Nhìn chung, kết quả thực nghiệm cho thấy sự mất cân bằng lớp là yếu tố chi phối toàn bộ bài toán phân loại CTG. Nếu chỉ dựa vào Accuracy, nhiều cấu hình có thể được xem là “tốt”; tuy nhiên, chỉ số này chưa phản ánh đầy đủ khả năng nhận diện lớp Pathological do lớp này chiếm tỉ lệ nhỏ trong dữ liệu. Vì vậy, việc ưu tiên Recall của lớp bệnh lý là lựa chọn phù hợp với bối cảnh ứng dụng, nơi chi phí bỏ sót một ca nguy cơ cao thường lớn hơn chi phí dự báo nhầm ở lớp bình thường.

Trên phương diện mô hình, SVM huấn luyện trên dữ liệu gốc là cấu hình đạt sự cân bằng tốt nhất giữa độ chính xác tổng thể và khả năng phát hiện ca bệnh. Việc hiệu chỉnh trọng số lớp theo cấu hình $\{1.0:1, 2.0:3, 3.0:7\}$ giúp Recall của lớp Pathological tăng từ 0,77 lên 0,94, trong khi Accuracy chỉ giảm rất nhẹ. Kết quả này cho thấy với dữ liệu y sinh mất cân bằng, điều chỉnh chi phí sai phân loại có thể đem lại hiệu quả thực tiễn rõ rệt hơn so với việc chỉ tối ưu một chỉ số tổng quát.

Kết quả của PCA và LDA cũng cho thấy giảm chiều không phải lúc nào cũng cải thiện hiệu năng phân loại. Với SVM và Softmax Regression,

dữ liệu gốc vẫn giữ được nhiều thông tin phân biệt hơn; ngược lại, LDA lại hỗ trợ Naive Bayes tốt hơn do tạo ra không gian biểu diễn phù hợp hơn với giả định phân phối của mô hình. Điều này cho thấy hiệu quả của bước tiền xử lý cần được đánh giá trong mối liên hệ với từng thuật toán cụ thể, thay vì được xem như một bước tối ưu mặc định.

Ngoài ra, độ chênh giữa kết quả trên tập huấn luyện và tập kiểm tra nhìn chung ở mức thấp, cho thấy các mô hình có khả năng khái quát tương đối ổn định trong phạm vi thực nghiệm đã xét. Ở bài toán hồi quy xấp xỉ xác suất đầu ra của SVM, KNN Regressor cho kết quả tốt hơn rõ rệt so với Linear Regression, qua đó gợi ý rằng mối quan hệ giữa đặc trưng đầu vào và xác suất bệnh lý có tính phi tuyến đáng kể.

Kết luận

Mô hình đã xây dựng và đánh giá một quy trình học máy hoàn chỉnh cho bài toán phân loại tình trạng sức khỏe thai nhi từ dữ liệu CTG, bao gồm các bước làm sạch dữ liệu, phân chia tập train/test, chuẩn hóa đặc trưng, giảm chiều, huấn luyện mô hình và đánh giá kết quả. Theo tiêu chí ưu tiên Recall của lớp Pathological, mô hình SVM với nhân RBF và cấu hình `class_weight={1.0:1, 2.0:3, 3.0:7}` là lựa chọn phù hợp nhất, với Accuracy 90,69%, Recall 0,94 và F1-score 0,91 đối với lớp bệnh lý. Kết quả này cho thấy trong bài toán dữ liệu y khoa mất cân bằng, việc lựa chọn tiêu chí đánh giá phù hợp và hiệu chỉnh trọng số lớp có ý nghĩa thực tiễn lớn hơn so với việc chỉ tối ưu độ chính xác tổng thể.

Kết quả thực nghiệm cũng cho thấy PCA và LDA không mặc nhiên cải thiện hiệu năng của mọi mô hình phân loại; với bộ dữ liệu CTG, hiệu quả của giảm chiều phụ thuộc vào từng thuật toán và mục tiêu đánh giá cụ thể. Do đó, đóng góp chính của báo cáo không chỉ nằm ở việc lựa chọn được một mô hình phù hợp, mà còn ở việc xây dựng được một quy trình thực nghiệm có hệ thống, làm rõ tác động của mất cân bằng lớp và đề xuất cách tinh chỉnh SVM phù hợp với ngữ cảnh y khoa.

Hạn chế

Mặc dù đạt được một số kết quả tích cực, mô hình vẫn còn một số hạn chế cần được nhìn nhận rõ ràng. Thứ nhất, việc đánh giá mô hình mới dừng ở các phép chia train/test cố định với ba tỉ lệ 8:2, 7:3 và 6:4, nên chưa phản ánh đầy đủ độ ổn định thống kê của kết quả trên nhiều lần lấy mẫu khác nhau. Thứ hai, dữ liệu sử dụng chỉ gồm một bộ dữ liệu thứ cấp từ Kaggle và chưa có bước kiểm định trên nguồn dữ liệu độc lập, do đó khả năng khái quát hóa trong bối cảnh lâm sàng thực tế vẫn cần được kiểm chứng thêm. Thứ ba, phạm vi mô hình trong báo cáo chủ yếu tập trung vào các phương pháp học máy cổ điển; quá trình tối ưu siêu tham số cũng mới thực hiện ở mức định hướng, chưa tiến hành tìm kiếm hệ thống trên toàn bộ không gian tham số. Cuối cùng, các đặc trưng

được sử dụng là các chỉ số đã được trích xuất sẵn từ tín hiệu CTG, nên mô hình chưa khai thác trực tiếp chuỗi tín hiệu gốc hoặc các thông tin lâm sàng bổ sung có thể giúp cải thiện khả năng dự đoán.

Đề xuất hướng phát triển

Từ những hạn chế trên, một số hướng phát triển tiếp theo có thể được xem xét. Trước hết, cần mở rộng quy trình đánh giá bằng *stratified k-fold cross-validation* hoặc kiểm định trên tập dữ liệu ngoài mẫu để tăng độ tin cậy của kết luận. Bên cạnh đó, việc tối ưu siêu tham số một cách hệ thống, kết hợp với các kỹ thuật xử lý mất cân bằng như resampling, cost-sensitive learning hoặc hiệu chỉnh xác suất, có thể giúp nâng cao thêm hiệu quả của mô hình. Ở mức độ mô hình hóa, mô hình có thể mở rộng sang các phương pháp tổ hợp như Random Forest, XGBoost hoặc các kiến trúc học sâu nếu có thể tiếp cận tín hiệu CTG thô. Cuối cùng, để tăng giá trị ứng dụng, cần bổ sung các công cụ giải thích mô hình và khảo sát khả năng tích hợp hệ thống dự đoán vào quy trình hỗ trợ ra quyết định lâm sàng.

Tài liệu tham khảo

- [1] TS. Cao Văn Chung, *Bài giảng Học máy*, Trường Đại học Khoa học Tự nhiên.
- [2] *Fetal Health Classification*, Kaggle dataset, <https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>.